

代码参考了前人的工作, 地址 <https://download.csdn.net/download/u012737234/8493615> 以及 [https://blog.csdn.net/weixin\\_39566131/article/details/100578284](https://blog.csdn.net/weixin_39566131/article/details/100578284), 点击 trainLenet.m 即可运行, 在此致谢。train-images.idx3-ubyte 超 25MB, 上传不了, 请见谅。

实验结论: LeNet-5 是一种用于手写体字符识别的非常高效的卷积神经网络, 准确率达 99.1%, 越到后期耗时越长; 卷积层的参数较少, 这是由卷积层的局部连接和共享权重所决定的。LeNe 的训练是一个循环过程: 前向传播训练—>反向传播调参—>更新参数—>再次训练, 直至训练结束就可拿去测试。其结构为输入的二维图像, 先经过两次卷积层到池化层, 再经过全连接层, 最后使用 softmax 分类作为输出层。

LeNet-5 的基本结构

层次	层名	作用	实现前向训练过程
0	输入层	输入样本, 大小为28*28	每次训练都会输入40张28x28的样本图片, 构成28x28x40的3维矩阵
1	C1, 卷积层	6种卷积核, size5*5, 随机生成6x5x5个weight, 6个bias	首先, 28x28x40的输入样本与6组5x5卷积核卷积, 得到结果为6组24x24x40的矩阵。然后, 给6组24x24x40矩阵的每一个组种的每个点上加上相应的6组bias, 送入Sigmoid函数激活, 此时得到结果为6组24x24x40矩阵。
2	S2, 池化层	6种6x1组weight, 6种bias	把上层得到的24x24x40矩阵做平均池化, 即卷积上[ 0.25 0.25; 0.25 0.25 ], 步长为2, 得到6组12x12x40的矩阵。
3	C3, 卷积层	卷积核有16种, size为5x5, 对上面6种卷积结果分别用上本层16种卷积核卷积, 所以初始化随机生成16x6x5x5	S2层输出的6组12x12x40矩阵与C3层的6组5x5卷积核, 组对应卷积后, 累加6组, 得到一组8x8x40的矩阵, 给6组8x8x40矩阵的每一个点加上第一组bias, 送入Sigmoid函数激活; 换第二种6组5x5的卷积核继续和S2层输出的6组12x12x40矩阵组对应卷积后, 累加6组, 得到第二组8x8x40的矩阵, 给6组8x8x40矩阵的每一个点加上第二组bias, 送入Sigmoid函数激活; 如此循环16次, 得到16组8x8x40矩阵。
4	S4, 池化层	随机生成16种6x1组weight, 16种bias	把上层得到的8x8x40矩阵做平均池化, 即卷积上[ 0.25 0.25; 0.25 0.25 ], 步长为2, 得到16组4x4x40的矩阵。
5	C5, 卷积层	随机生成120x256个weight, 120个bias	把S4层输出的16组4x4x40的矩阵展开为256x40的矩阵, 用C5层120x256的weight卷积256x40的展开矩阵得到120x40的矩阵, 给矩阵的每一行加上不同的bias, 共120行, 之后送入Sigmoid函数激活。
6	F6, 全连接层	随机生成84x120个weight, 84个bias	F6层84x120的weight卷积C5层输出的120x40矩阵, 得到84x40的矩阵, 给矩阵的每一行加上不同的bias, 共84行, 之后送入Sigmoid函数激活。
7	Soft,输出层	全连接层, 初始化随机生成10x84个weight	Soft层10x84的weight卷积F6层输出的84x40矩阵, 得到10x40的矩阵, 给矩阵的每一行加上不同的bias, 共10组; 找该矩阵的每一列最大值, 用原10x40矩阵的每一列, 减去该列的最大值; 对10x40矩阵的每一个数值求e指数, 即送入exp函数, 其结果除以10x40矩阵的行求和 (1x40), 得到10x40的结果。

核心代码阐释 trainLenet.m:

```
clear;clc;

%%
=====

===

%load data
imageDim = 28;
numclasses = 10;
images = loadMNISTImages('train-images.idx3-ubyte');
images = reshape(images,imageDim,imageDim,[]);
labels = loadMNISTLabels('train-labels.idx1-ubyte');
labels(labels == 0) = 10;
%%输入层: 输入训练样本, 为了适应数据集把大小为 28x28

%% initialparameters
```

```

lenet.layers = {
    struct('type','i')
    struct('type','C1','outputmaps',6,'kernelsize',5) %卷积层，卷积核有 6 种，size 为 5x5，初始化随机生成 6x5x5 个 weight，6 个 bias，等待学习
    struct('type','S2','scale',2) %代码里池化层，初始化随机生成 6 种 6x1 组 weight，6 种 bias
    struct('type','C3','outputmaps',16,'kernelsize',5) % : 卷积层，卷积核有 16 种，size 为 5x5，对上面 6 种卷积结果分别用上层 16 种卷积核卷积，所以初始化随机生成 16x6x5x5 个 weight
    struct('type','S4','scale',2) %池化层，代码里初始化随机生成 16 种 6x1 组 weight，16 种 bias
    struct('type','C5','outputmaps',120) %卷积层，初始化随机生成 120x256 个 weight，120 个 bias，等待学习
    struct('type','F6','outputmaps',84) %全连接层，初始化随机生成 84x120 个 weight，84 个 bias，等待学习
    struct('type','Soft','num_classes',10) %输出层，全连接层，初始化随机生成 10x84 个 weight，10 个 bias，等待学习
};

```

```

lenet = initialParameters(lenet,images);

```

```

%% train the cnn

```

```

opts.alpha = 1;

```

```

opts.batchsize = 40; %代码中每次训练都会输入 40 张 28x28 的样本图片，构成 28x28x40 的 3 维矩阵

```

```

opts.numepochs = 20;

```

```

lenet = cnnTrain(lenet,images,labels,opts); %cnnTrain 源代码涉及到 cnnff 和 cnnbp, cnnff 是前向传播训练，cnnbp 即反向传播调参——delta 反向传播就是从最底层，即 Soft 层，向上层传参。

```

```

%% test the cnn

```

```

testImages = loadMNISTImages('t10k-images.idx3-ubyte');

```

```

testImages = reshape(testImages,imageDim,imageDim,[]);

```

```

testLabels = loadMNISTLabels('t10k-labels.idx1-ubyte');

```

```

testLabels(testLabels == 0) = 10;

```

```

lenet = cnnff(lenet,testImages);

```

```

a = lenet.layers{8}.a;

```

```

[~,preds] = max(lenet.layers{8}.a,[],1);

```

```

preds = preds';

```

```

acc = sum(preds == testLabels) / length(preds);

```

```
fprintf('Accuracy is %f\n',acc);
```

程序结果:

epoch1/20

历时 48.254550 秒。

epoch2/20

历时 49.346237 秒。

epoch3/20

历时 52.720203 秒。

epoch4/20

历时 55.095996 秒。

epoch5/20

历时 58.191246 秒。

epoch6/20

历时 60.588026 秒。

epoch7/20

历时 65.960499 秒。

epoch8/20

历时 74.379831 秒。

epoch9/20

历时 84.641069 秒。

epoch10/20

历时 99.915916 秒。

epoch11/20

历时 122.869474 秒。

epoch12/20

历时 150.449686 秒。

epoch13/20

历时 181.499596 秒。

epoch14/20

历时 205.628320 秒。

epoch15/20

历时 232.310099 秒。

epoch16/20

历时 260.782082 秒。

epoch17/20

历时 289.569491 秒。

epoch18/20

历时 299.611985 秒。

epoch19/20

历时 320.018952 秒。

epoch20/20

历时 346.295471 秒。

Accuracy is 0.991000